

WB1

Andre Nieri, Livio Kuze

```
library(readxl)

data = read_excel("Pesquisa.xlsx", range = "A1:M178")
df = as.data.frame(data)
head(df)

##      OBS idade temceo temceo2 enssup tememp tememp2 vendas lucro  mglucro grad
## 1      1    49      2      4      1      9      81   6200   966 15.580646    1
## 2      2    43     10     100     1     10     100    283    48 16.961130    1
## 3      3    51      3      9      1      9      81    169    40 23.668638    1
## 4      4    55     22     484     1     22     484   1100   -54 -4.909091    0
## 5      5    44      6      36     1      8      64    351    28  7.977208    1
## 6      6    64      7      49     1      7      49  19000   614  3.231579    1
##      salario valmkt
## 1      1161  23200
## 2      600   1100
## 3      379   1100
## 4      651   1000
## 5      497    387
## 6     1067   3900

model = lm(salario ~ temceo, data = df)
summary(model)

##
## Call:
## lm(formula = salario ~ temceo, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -977.8 -345.9 -169.4  263.8 4373.9
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  772.426    65.676   11.761  <2e-16 ***
## temceo       11.746     6.148    1.911   0.0577 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 583.2 on 175 degrees of freedom
## Multiple R-squared:  0.02043,    Adjusted R-squared:  0.01484
## F-statistic: 3.651 on 1 and 175 DF,  p-value: 0.05769

salario_hat = predict(model, newdata = data.frame(temceo=10))
salario_hat
```

```
##          1
## 889.8876

temceo_coef = coef(model)["temceo"]
model_conselho = 300 + temceo_coef * 10
model_conselho

## temceo
## 417.4613

model_valmkt = lm(salario ~ valmkt, data = df)
summary(model_valmkt)

##
## Call:
## lm(formula = salario ~ valmkt, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1006.7   -325.3   -112.7    235.2   4511.0
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 732.44174    46.39372   15.788 < 2e-16 ***
## valmkt       0.03706     0.00630    5.882 2.01e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 538.4 on 175 degrees of freedom
## Multiple R-squared:  0.1651, Adjusted R-squared:  0.1603
## F-statistic: 34.6 on 1 and 175 DF, p-value: 2.009e-08
```

1. Interpretação:

O intercepto nos dá um valor de 772.43 mil dólares de salário base, e o coeficiente associado à experiência nos dá um valor de 11.75 mil dólares para cada ano adicional de experiência do CEO.

2. Usando o modelo ajustado (intercepto=772.43, temceo=11.75) teríamos uma remuneração de 889.89 mil dólares.

Usando o modelo do conselho com o coeficiente ajustado anteriormente (intercepto=300, temceo=11.75) teríamos uma remuneração de 417.46 mil dólares.

3. Analisando os coeficientes, o intercepto é altamente significativo ($p < 2e-16$), mas o coeficiente para temceo ($p = 0.0577$) não tem significância ao nível de 5%, o que sugere evidência fraca de relação `salario ~ temceo`.

Analisando o R^2 ($R^2 = 0.02043$), podemos dizer que o modelo explica apenas cerca de 2% da variação do salário, o que indica que há outras variáveis importantes faltando no modelo. O erro residual ($rse = 538.2$) é muito alto perto do valor ajustado de 11.75, indicando muita dispersão nos dados.

Ao tentar outros modelos de regressão simples, encontramos o modelo `salario ~ valmkt` com uma significância maior: (intercepto=732.44, valmkt=0.03706), nesse caso o intercepto não faz muito sentido econômico, pois seria de uma empresa com valor de mercado zero, mas o coeficiente de valmkt indica a relação de aumento de 0.037 mil dólares para cada aumento de 1 milhão de valor de mercado da empresa, com significância alta ($p < 2e-08$). No entanto, esse modelo ainda não explica a maior parte da variabilidade do salário, capturando cerca de 16.5% da variação total ($R^2 = 0.1651$).