

Workbook3

Andre Nieri, Livio Kuze

```
library(lmtest)
library(sandwich)

data = read.csv('paises.csv')
head(data)

##      X COUNTRY YEAR NHOUSEHOLDS share_water share_sewage share_ownership
## 1 159      35 2002    7085204  0.65573239          NA    0.05319803
## 2 179      42 2011    1166190  0.01278308  0.02484297    0.37312216
## 3  14       2 2001    2104710  0.29643805  0.61298885    0.25171733
## 4 170      39 1991    3031612  0.97754446          NA    0.17863979
## 5  50      11 1996     144550          NA          NA    0.10346690
## 6 118      28 1990     539850  0.19155510  0.55738643    0.10468127
##   avg_household_income poverty_household_share
## 1             1508.0339              86.2
## 2             17969.0840               0.1
## 3             5267.6562              22.8
## 4             910.1062              57.6
## 5                NA                NA
## 6            10403.1421              23.7

n = nrow(data)
n_nona = sum(complete.cases(data[, c("avg_household_income", "share_sewage", "share_water")]))

cat("Total Rows =", n, "\n")

## Total Rows = 60

cat("Rows without NA =", n_nona, "\n")

## Rows without NA = 24

model = lm(avg_household_income ~ share_sewage + share_water, data = data)
summary(model)

##
## Call:
## lm(formula = avg_household_income ~ share_sewage + share_water,
##     data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -10489  -3787  -1603   1939   27600
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    24544      2741    8.955 1.29e-08 ***
```

```

## share_sewage    -26654      8768  -3.040  0.00623 **
## share_water     -5267      9221  -0.571  0.57394
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8252 on 21 degrees of freedom
## (36 observations deleted due to missingness)
## Multiple R-squared:  0.5339, Adjusted R-squared:  0.4895
## F-statistic: 12.03 on 2 and 21 DF,  p-value: 0.0003302
robust_model = coeftest(model, vcov = vcovHC(model, type = "HC1"))
print(robust_model)

##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   24543.9     3996.1   6.1419 4.291e-06 ***
## share_sewage -26654.3     6696.7  -3.9802 0.0006812 ***
## share_water  -5267.0      3065.0  -1.7185 0.1004243
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Nota metodológica:

A base de dados original fornecida para esta análise compreende um painel com 60 observações de países em diferentes períodos. No entanto, identifica-se uma severa ausência de dados nas variáveis explicativas utilizadas, especificamente em `share_water` e `share_sewage`.

Metodologicamente, optou-se por restringir a estimação do modelo econométrico aos casos completos, eliminando as linhas com dados faltantes. Essa escolha preserva a integridade estatística e evita as distorções artificiais de variância inerentes a métodos de imputação arbitrários por médias. Como consequência direta, a amostra efetiva de regressão é reduzida de 60 para 24 observações.

Isso impõe duas limitações importantes à interpretação dos resultados:

- i) Perda de Poder Estatístico: O tamanho diminuto da amostra ($n = 24$) inflaciona os erros padrão dos estimadores de Mínimos Quadrados Ordinários (MQO), elevando o rigor necessário para a rejeição da hipótese nula de não-significância.
- ii) Viés de Seleção Amostral: A omissão de indicadores de saneamento básico não ocorre de forma aleatória no cenário global; ela concentra-se historicamente em nações de menor renda, menor capacidade institucional ou em estado de vulnerabilidade socioeconômica. Portanto, as estimativas resultantes refletem predominantemente o comportamento de países com estruturas estatísticas mais consolidadas, configurando um limite inferior (lower bound) do impacto real da privação de saneamento sobre o desenvolvimento.

Questões:

1)

Temos o modelo: $avg_household_income_{j,t} = \alpha_0 + \alpha_1 share_sewage_{j,t} + \alpha_2 share_water_{j,t} + \epsilon_{j,t}$

Observamos os seguintes coeficientes:

Intercepto ($\alpha_0 = 24544$): Representa a renda domiciliar média anual esperada de um país com acesso universal à água e esgoto. O valor esperado será de \$ 24.544,00 (em dólares PPP).

Coefficiente de `share_sewage` ($\alpha_1 = -26654$): Representa o impacto na renda de um país ao mover-se de um cenário de acesso universal (100% = 1) para a privação total (0% = 0) de esgoto. Mantendo o acesso à água constante, o aumento de 1% na proporção de domicílios sem esgoto tratado está associado a uma redução de \$ 266,54 dólares PPP na renda domiciliar média anual.

Coefficiente de `share_water` ($\alpha_2 = -5267$): Representa o impacto correspondente para a privação total de acesso à água. Mantendo o acesso ao tratamento de esgoto constante, o aumento de 1% na proporção de domicílios sem água está associado a uma redução de \$ 52,67 dólares PPP na renda domiciliar média anual.

2)

Temos somente o coeficiente de `share_sewage` ($p\text{-valor} = 0.00623$) estatisticamente significantes a 5%. Nota: também é significativa a 1%.

No caso, o coeficiente de `share_water` ($p\text{-valor} = 0.57394$) não é estatisticamente significativo a 5%.

Conclusão: Sob a premissa de homocedasticidade, apenas a falta de tratamento de esgoto pareceria correlacionado significativamente com menor desenvolvimento econômico do país.

3)

Ao aplicar a correção de White para heteroscedasticidade, ainda temos somente o coeficiente de `share_sewage` ($p\text{-valor} = 0.0006812$) significativo a 5%. Nota: agora também é significativo a 0.1%.

O coeficiente de `share_water` ($p\text{-valor} = 0.1004243$) continua não sendo estatisticamente significativo a 5%.

Notas Finais:

Há evidência de heteroscedasticidade nos dados, devido à queda dos erros padrões dos coeficientes (queda de ~23.6% em share_sewage, e de ~66.8% em share_water).

O tamanho da amostra pode ter impactado a análise, reduzindo o poder do teste. É possível que o coeficiente de share_water (que ficou com p-valor ~0.10) possa ter ficado não-significante a 5% justamente porque a amostra ficou pequena demais para capturar o efeito com precisão, e não porque acesso a água não importa na vida real.