

Workbook5

Andre Nieri, Livio Kuze

```
library(data.table)
library(AER)
library(lmtest)
library(sandwich)

full_data = fread(
  "censo_data_family_size.csv",
  select=c("family_number_births",
           "family_number_children",
           "first_child_years_of_education",
           #"first_birth_ismultiplebirth",
           "second_birth_ismultiplebirth"))

filtered_data =
  full_data[family_number_children >= 2]

avg_no_children = mean(filtered_data$family_number_children, na.rm = TRUE)
cat("Tamanho Familiar Médio =", avg_no_children, "\n")

## Tamanho Familiar Médio = 2.69521

model_ols = lm(first_child_years_of_education ~ family_number_children, data = filtered_data)
print(summary(model_ols))

##
## Call:
## lm(formula = first_child_years_of_education ~ family_number_children,
##     data = filtered_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.9277 -1.9277  0.0723  2.0723 10.6301
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    6.706633   0.010147   660.9   <2e-16 ***
## family_number_children -0.389459   0.003503  -111.2   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.059 on 679313 degrees of freedom
## (12098 observations deleted due to missingness)
## Multiple R-squared:  0.01787,    Adjusted R-squared:  0.01787
## F-statistic: 1.236e+04 on 1 and 679313 DF,  p-value: < 2.2e-16
```

```

n_second_birth_multiple = sum(filtered_data$second_birth_ismultiplebirth == 1, na.rm = TRUE)
cat("Total de famílias com segundo parto com mais de uma criança = ", n_second_birth_multiple, "\n")

## Total de famílias com segundo parto com mais de uma criança = 9632
stage_1 = lm(family_number_children ~ second_birth_ismultiplebirth, data = filtered_data)
print(summary(stage_1))

##
## Call:
## lm(formula = family_number_children ~ second_birth_ismultiplebirth,
##     data = filtered_data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.8018 -0.7035 -0.7035  0.2965 12.2965
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      2.703500   0.001324  2042.7 <2e-16 ***
## second_birth_ismultiplebirth 1.098306   0.010923   100.5 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.064 on 656056 degrees of freedom
## (35355 observations deleted due to missingness)
## Multiple R-squared:  0.01518,    Adjusted R-squared:  0.01518
## F-statistic: 1.011e+04 on 1 and 656056 DF,  p-value: < 2.2e-16

model_iv = ivreg(first_child_years_of_education ~ family_number_children | second_birth_ismultiplebirth
                 data = filtered_data)

coeftest(model_iv, vcov = vcovHC(model_iv, type = "HC1"))

##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      6.686092   0.079714  83.876 < 2.2e-16 ***
## family_number_children -0.368118   0.029275 -12.574 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

1

O tamanho familiar médio, para famílias com mais de um filho, é de aprox. 2.695 filhos.

2

Temos o modelo: $first_child_years_of_education_i = \beta_0 + \beta_1 family_number_children_i + \epsilon_i$

Observamos os seguintes coeficientes:

Intercepto ($\beta_0 = 6.706$): Aqui não faz muito sentido, pois representa o número teórico de anos de educação esperada para o primeiro filho caso a família tivesse zero filhos (apenas uma referência matemática, pois estamos filtrando as famílias com dois ou mais filhos).

Coefficiente de family_number_children ($\beta_1 = -0.389$): Cada filho adicional na família está associado a uma redução média de aproximadamente 0,39 anos (~4.7 meses) de estudo na trajetória de educação do primeiro

filho.

Significância: os p-valores para o intercepto e o coeficiente de `family_number_children` são extremamente significativos (`p-valor < 2e-16` para ambos), com certeza significantes a 5%.

3

A estimativa obtida não é crível como um efeito causal, pois o modelo sofre de problema de endogeneidade, devido ao viés de variáveis omitidas. Para que o coeficiente de MQO representasse verdadeiramente o impacto causal do número de filhos sobre a educação do mais velho, seria necessário que a decisão de ter mais filhos fosse aleatória na sociedade. Na realidade, essa decisão e a decisão sobre educação dependem de vários fatores socioeconômicos (ex: renda familiar) e culturais (ex: escolaridade dos pais, background cultural) não incluídos na regressão simples.

4

Total de famílias com segundo parto com mais de uma criança = 9632

5

Deve satisfazer:

- Hipótese de relevância do instrumento ($Cov(Z, X) \neq 0$), ou seja, o instrumento deve estar correlacionado com a variável endógena. A ocorrência de gêmeos/múltiplos gera um choque exógeno positivo e imediato no número total de filhos.
- Hipótese de exogeneidade ($Cov(Z, \epsilon) = 0$), ou seja, o instrumento afeta a variável dependente (Y) única e exclusivamente através do canal da variável endógena (X). A ocorrência de parto múltiplo é tratado como choque puramente biológico e aleatório.

Possíveis violações:

- Choque financeiro: o parto de dois ou mais filhos gera uma pressão financeira no orçamento familiar (vários custos de cuidar da criança serão duplicados/multiplicados)
- Choque de tempo e atenção: Gêmeos exigem maior atenção parental, que pode remover a atenção e tempo dos pais sobre a educação do primeiro filho.

6

Temos o modelo: $family_number_children_i = \beta_0 + \beta_1 second_birth_ismultiplebirth_i + \epsilon_i$

Coeficiente de `second_birth_ismultiplebirth` ($\beta_1 = 1.098$): O choque biológico de ter gêmeos (ou parto múltiplo) no segundo nascimento causa um aumento médio esperado de aprox. 1.10 filhos no tamanho final da família, controlando pelo fato de a família já ter atingido o segundo parto.

Significância: os p-valores para o intercepto e o coeficiente de `second_birth_ismultiplebirth` são extremamente significativos (`p-valor < 2e-16` para ambos), com certeza significantes a 5%. O erro padrão de 0.0109 é baixo, e a t-statistic de 100.5 e F-statistic de $1.011 \cdot 10^4$, mostram que não é um instrumento fraco.

7

Temos o modelo: $first_child_years_of_education_i = \beta_0 + \beta_1 family_number_children_i + \epsilon_i$

Coeficiente de `family_number_children` ($\beta_1 = -0.368$): Isolando apenas a variabilidade exógena do tamanho da família (causada estritamente pelo choque biológico do nascimento de gêmeos no segundo parto), cada filho adicional na família causa uma redução média de aproximadamente 0.37 anos (cerca de 4.4 meses) de estudo na educação do primeiro filho. Esse coeficiente estima o Local Average Treatment Effect (LATE) sobre as famílias afetadas pelo instrumento.

Significância: os p-valores para o intercepto e o coeficiente de `family_number_children` são extremamente significativos (`p-valor < 2e-16` para ambos), com certeza significantes a 5%. O erro padrão robusto de 0.0292 é baixo.